

Estimación de la Canasta Básica Alimentaria (CBA) vía Web Scraping

Arquitectura de Software, Módulos de Extracción, Esquema de Datos y API REST

REPOSITORIO	MÓDULO CORE	ORQUESTACIÓN	ESTADO SISTEMA
equipo3-bordon-gandini	Python 3.10+ / Scraping	GitHub Actions (CI/CD)	Producción / Activo

Resumen Ejecutivo del Sistema

El sistema proporciona una solución integral para el seguimiento continuo del costo de la Canasta Básica Alimentaria (CBA) en Argentina. Mediante el uso de agentes de extracción web automáticos, homologación nutricional por Adulto Equivalente y almacenamiento desacoplado, se eliminan los sesgos de actualización diferida, ofreciendo métricas de precios de productos esenciales en tiempo real.

1. VISIÓN GENERAL Y PROPÓSITO DEL PROYECTO

01

El cálculo oficial de la Canasta Básica Alimentaria suele presentar desfases temporales respecto a la dinámica inflacionaria real. Este desarrollo automatiza la captura directa de precios minoristas desde portales e-commerce de supermercados e hipermercados, mapeándolos contra la tabla nutricional estandarizada (INDEC / Adulto Equivalente: 2.750 kcal/día).

- **Captura No Invasiva:** Recolección periódica programada sin afectar los servidores de origen.
- **Normalización de Unidades:** Conversión automática de precios por empaque a precios por unidad estándar (\$/kg, \$/L, \$/unidad).
- **Evaluación Calórica:** Ponderación directa según los requerimientos mensuales del Adulto Equivalente.
- **Servicio Abierto:** Exposición de resultados mediante archivos planos (CSV) y endpoints REST en formato JSON.

2. ARQUITECTURA DEL FLUJO DE DATOS

02



<code>`scraper.py`</code> EXTRACTOR PRINCIPAL Script escrito en Python encargado de efectuar las peticiones a las tiendas virtuales. Parsea el DOM o las respuestas API internas, extrae descripciones, marcas y precios, calculando la conversión a unidades estándar.	<code>`api/index.py`</code> MICROSERVICIO API Servicio de consulta desacoplado. Lee los datos persistidos en los archivos CSV y expone endpoints ligeros que retornan el histórico de totales y el desglose de productos en formato JSON.	<code>`scraper.yml`</code> GITHUB WORKFLOW Pipeline de Integración Continua configurado en GitHub Actions. Ejecuta de forma programada (Cron) el scraper, actualiza los datasets CSV y versiona los cambios directamente en el repositorio.
--	--	--

4. ESQUEMA DE ARCHIVOS Y DICCIONARIO DE DATOS

A continuación se detallan las estructuras de los tres archivos de datos centrales del proyecto:

ARCHIVO DATASET	PROPÓSITO PRINCIPAL	CAMPOS CLAVE / COLUMNA	ACTUALIZACIÓN
<code>`cba_tabla_nutricional.csv`</code>	Matriz fija de ponderadores nutricionales e ingesta diaria requerida por Adulto Equivalente.	<code>`rubro`</code> , <code>`producto_generico`</code> , <code>`gramos_diarios`</code> , <code>`unidad_referencia`</code> , <code>`ponderador`</code>	Estática (Referencia)
<code>`cba_historico_detalle.csv`</code>	Registro desagregado de precios individuales capturados por producto, comercio y fecha.	<code>`fecha`</code> , <code>`comercio`</code> , <code>`rubro`</code> , <code>`producto_nombre`</code> , <code>`precio_relevado`</code> , <code>`precio_estandar`</code>	Diaria / Programada
<code>`cba_historico_totales.csv`</code>	Resumen consolidado del costo total mensual de la CBA calculada y variaciones porcentuales.	<code>`fecha`</code> , <code>`costo_cba_total`</code> , <code>`variacion_diaria`</code> , <code>`variacion_acumulada`</code> , <code>`items_validados`</code>	Diaria / Programada

5. METODOLOGÍA DE CÁLCULO Y HOMOLOGACIÓN NUTRICIONAL

El cálculo del costo total se basa en la conversión estandarizada del precio por unidad física al consumo mensual estipulado para la unidad de medida "Adulto Equivalente" (varón de 30 a 60 años con actividad moderada, equivalente a 2.750 kcal/día):

$$\text{Precio Estándar (\$/Unidad)} = (\text{Precio Relevado} / \text{Cantidad Presentación}) \times \text{Unidad de Referencia}$$

$$\text{CBA Total Adulto Eq. (\$/Mes)} = \sum [\text{Precio Estándar}_i \times (\text{Gramos Diarios}_i / 1000) \times 30.4167]$$

*Nota: El factor constante 30.4167 representa la cantidad promedio de días en un mes del año civil (365 / 12).

Para desplegar o probar el entorno de desarrollo en un equipo local, siga la secuencia de comandos descrita a continuación:

```
# 1. Clonar el repositorio de código fuente git clone https://github.com/usuario/equipo3-bordon-gandini.git cd equipo3-bordon-gandini-main # 2. Crear y activar un entorno virtual aislado en Python python3 -m venv venv source venv/bin/activate # En Windows use: venv\Scripts\activate # 3. Instalar las dependencias del proyecto pip install -r requirements.txt # 4. Ejecutar el proceso manual de extracción de precios python scraper.py # 5. Iniciar el servicio local de la API REST python api/index.py
```

7. AUTOMATIZACIÓN CI/CD CON GITHUB ACTIONS

El archivo ``.github/workflows/scrapper.yml`` orquesta la ejecución periódica mediante sintaxis ``cron``. El workflow realiza los siguientes pasos de manera desatendida:

- **Disparo Programado:** Configurado para ejecutarse diariamente en horarios de baja demanda.
- **Configuración del Runner:** Instala la versión especificada de Python y sus dependencias.
- **Ejecución e Inspección:** Corre ``scraper.py``, valida la integridad de los CSV generados y verifica que no existan valores nulos críticos.
- **Persistencia de Cambios:** Efectúa ``git commit`` y ``git push`` automáticamente utilizando el ``GITHUB_TOKEN`` para actualizar la rama principal.

8. RESILIENCIA, MONITOREO Y BUENAS PRÁCTICAS

Manejo de Variaciones en Portales Dado que la estructura HTML de los supermercados cambia periódicamente, el scraper implementa selectores flexibles y fallbacks de precios ponderados para evitar interrupciones o lecturas sesgadas cuando un ítem no está en stock.	Gobernanza de Datos y Escalabilidad Los archivos de detalle histórico se particionan periódicamente para evitar la degradación en los tiempos de respuesta de la API. Se recomienda la depuración de valores atípicos (outliers) mediante filtros intercuartílicos.
---	--